### MU5IN852 Bases de Données Large Echelle

# Analyse multidimensionnelle en SQL

Hubert.Naacke@lip6.fr

### Objectifs

- Notions de schéma multidimensionnel
- Requêtes d'analyse multidimensionnelle
- Efficacité des requêtes multidimensionnelles à large échelle

# Motivations dans le contexte big data

- Besoin d'analyse multidimensionnelle
  - Analytics, tableau de bord,
  - Analyse en ligne (online) « instantanée »
- Besoin de solution unifiée
  - Un même environnement pour la préparation, l'analyse, la prédiction, ...
- Solution évolutive
  - Analyse exprimée dans un langage déclaratif
    - bénéficie des progrès en optimisation de requêtes
      - Transformation «requête vers programme» toujours plus efficace
    - bénéficie des progrès technologiques sous-jacents
      - calcul parallèle SIMD dans un processeur, ...

### Rappels sur les modèles de données

- Modèle Entité/Association
  - Une entité a des attributs
  - Une association entre plusieurs entités
    - Une association peut avoir des attributs d'association
- Modèle relationnel (SQL)
  - Relation : une table
  - Identifiant : clé d'une table
  - Référence à un identifiant : lien entre relations
- Modèle multidimensionnel
  - Fait, mesure
  - Dimension, hiérarchie

### Fait et mesure

- Une relation principale représente un fait
  - Un type d'événement à analyser
  - Exple: Achat(<u>numA</u>, client, date, magasin, produit, prix)
- Identifiant d'un fait
  - Identifiant propre au fait. Exple: numA
  - Ou identifiant composé
- Mesure du fait
  - Un attribut décrivant le fait
  - Exple : le prix d'achat d'un produit

### Dimensions et hiérarchie

- Dimensions
  - Les entités associées au fait
  - Un fait peut référencer plusieurs dimensions
  - Exple: date, client, magasin
- Dimension hiérarchique
  - Objectif : offrir de multiples analyses
    - Analyse globale très synthétique → ... → analyse fine
  - Une dimension peut être organisée en plusieurs niveaux
    - Niveau supérieur global → ...→ Niveau inférieur détaillé
    - Une table par niveau

# Exemples de dimensions hiérarchiques

- Dimension temporelle
  - Date(horodatage, idJour)
  - Jour(idJour, nom, idMois)
  - Mois (idMois, nom, idAnnée)
  - ...
- Dimension géographique
  - Magasin(gps, idVille)
  - Ville(idVille, nom, idPays)
  - Pays(idPays, nom, continent)
- Catégorie d'un produit en 3 niveaux
  - Famille → rayon → catégorie détaillée
- Classification biologique
  - famille  $\rightarrow$  genre  $\rightarrow$  espèce

### Forme des schémas

- Etoile simple
  - La table de faits est directement reliée à chaque dimension
  - dimension sans hiérarchie
- Etoile avec des branches « longues »
  - Le fait est relié au niveau inférieur de chaque dimension
  - dimensions hiérarchiques
- Flocon
  - une dimension peut être décrite par plusieurs hiérarchies
- Formes réelles
  - Schéma formé de plusieurs étoiles ou flocons
  - Tenir compte des associations N-N.
    - Exemple : vente de médicaments. Un médicament peut contenir plusieurs molécules. Nb de ventes par molécule.

## Exemple de faits

#### Les visites

photoID 🔺	personID 🔺	date 🔺	lon 📤	lat 🔺	note 🔺
p1	Bob	2020-09-03	41.5	12.8	3
p2	Alice	2020-09-01	41.6	12.8	5
р3	Bob	2020-09-04	41.6	13.2	1
p4	Bob	2020-09-04	40.1	12	2
p5	Alice	2020-09-04	40.1	12	2
p6	Alice	2020-09-05	41.6	12.7	4
p7	Alice	2020-10-05	41.8	12.8	4
p8	Carole	2019-12-25	30.1	10.1	2
p9	David	2019-12-25	30.1	10.1	1
p10	Eva	2019-12-25	30.1	10.1	5
p11	Eva	2019-12-26	31.1	10.1	3
p12	Alice	2020-02-01	32.1	12.1	3
p13	Bob	2020-02-01	32.1	12.1	5
p14	Carole	2020-02-01	32.1	12.1	2
p15	Carole	2019-11-11	49.1	10.1	1
p16	Alice	2019-12-25	30.1	10.1	4
p17	Alice	2020-02-02	49.1	10.1	5

## Exemple de dimensions

#### Date

date 🔺	jour 🔺	mois 🔺	annee 🔺
2019-11-11	11	11	2019
2019-12-25	25	12	2019
2019-12-26	26	12	2019
2020-02-01	1	2	2020
2020-02-02	2	2	2020
2020-09-01	1	9	2020
2020-09-03	3	9	2020
2020-09-04	4	9	2020

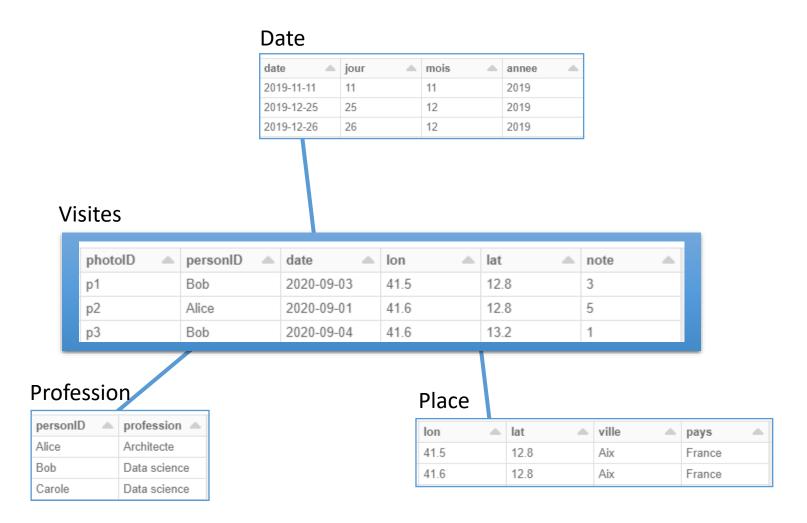
#### Place

lon 🔺	lat 🔺	ville	pays 🔺
41.5	12.8	Aix	France
41.6	12.8	Aix	France
41.6	12.7	Nice	France
41.8	12.8	Marseille	France
41.6	13.2	Rome	Italie
40.1	12	Oslo	Norvege
30.1	10.1	Paris	France
31.1	10.1	StDenis	France

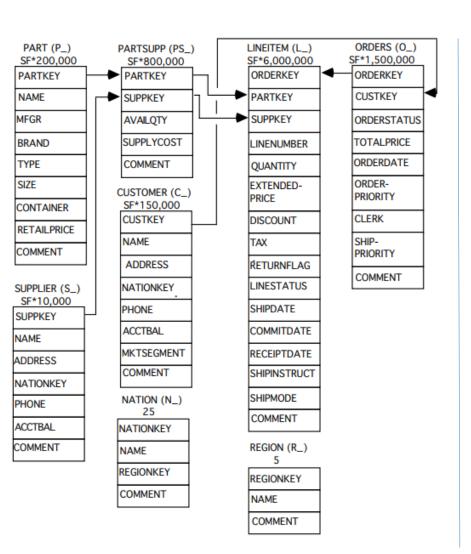
#### **Profession**

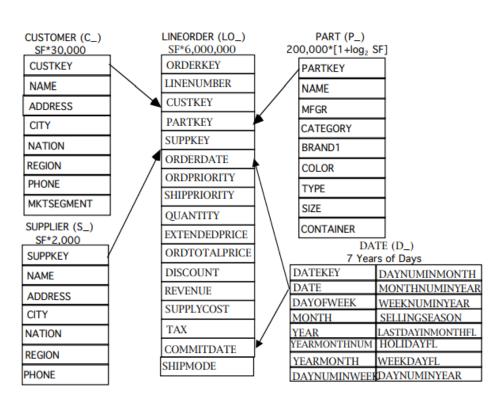
personID	profession 🔺
Alice	Architecte
Bob	Data science
Carole	Data science
David	Architecte
Eva	Vendeuse
Franck	Vendeur
Greta	Economiste

## Exemple de schéma en étoile



### Exemple: le benchmark TPC-H





#### Schéma en étoile pour TPC-H

https://www.cs.umb.edu/~xuedchen/research/publications/StarSchemaB.PDF

### Principaux types d'analyse

Agrégation

- Dimensions
- Fonctions d'agrégation
- Cube = multi agrégation

Fenêtres

- Fonctions sur fenêtre
- Fenêtre partitionnée
- Fenêtre glissante

## Agrégation:

group by ROLLUP et group by CUBE

### Agrégations : problème

- Explosion du nombre de regroupements potentiels à calculer
  - Nombreuses dimensions
  - Dimensions avec nombreux niveaux
- Problème lié à l'exécution
  - Calculer efficacement un ensemble d'agrégations?
    - Factoriser les calculs communs entre deux agrégations
- Problème lié au langage
  - Exprimer de manière déclarative un ensemble d'agrégations ?

## Factoriser le calcul d'agrégats Exemple

Foot (numMatch, date, buts)

```
(m1, 25/12/2019, 3) (m2, 16/3/2020,2) (m3, 31/8/2020, 1) (m4, 14/7/2019, 5) (m5, 4/7/2019, 2)
```

- Mois (jour, numMois) numMois de M1 à M24
- Année (numMois, année) de 2019 à 2020
- Nombre total de buts par année
  - 2019: 3+5+2=10 2020: 2+1=3
- Nombre total de buts: deux méthodes possibles
  - Partir des données initiales: 3+2+1+5+2=13
  - Partir de l'agrégat déjà calculé: 10+3=13
    - correct car la fonction d'agrégation est associative
      - (v11 + v12 + v13 + v21 + v22) = (v11 + v12 + v13) + (v21+v22)
    - moins d'opérations donc plus efficace
- Rmq: factorisation possible des agrégations non associatives pouvant s'exprimer avec des fonctions associatives:
  - Exple exprimer avg() avec des sum()

# Exprimer un ensemble d'agrégations : ROLLUP

- Rollup sur une seule dimension hiérarchique
- tables Fait(n1, mesure) et Dimension (n1,n2, ...)
- Requête

  Select n1, n2, n3, ..., agrégation(...), ...

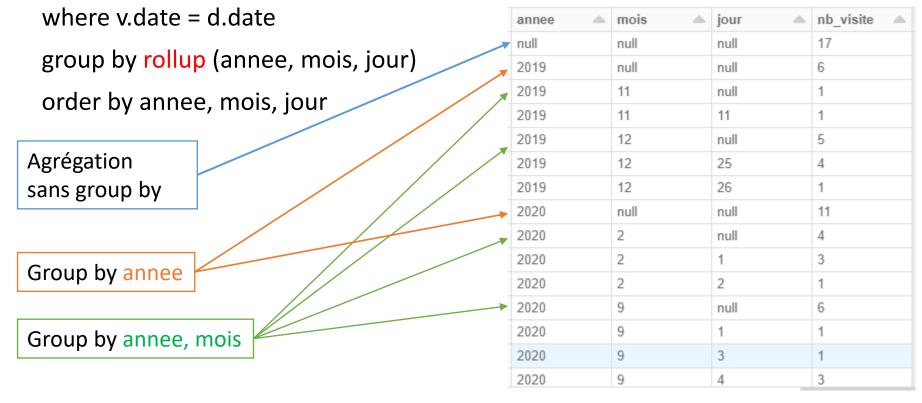
  From Fait f, Dimension d

  Where f.n1 = d.n1

  Group by ROLLUP (n1, n2, n3, ...)
- Le résultat contient plusieurs niveaux d'agrégation
  - Niveau général
  - Niveau n1
  - Niveau n1, n2
  - Niveau n1, n2, n3
  - ...

### Exemple de ROLLUP (1)

select annee, mois, jour, count(\*) as nb\_visite from Visite v, DateDimension d



### Exemple de ROLLUP (2)

#### Faits: VisiteGPS

photoID	personID	date	<u>.</u>	gps	note
p1	Bob	2020-09-03		▶ {"lon": 41.5, "lat": 12.8}	3
p2	Alice	2020-09-01		▶ {"lon": 41.6, "lat": 12.8}	5
				<b>A</b>	

#### **Dimension: PlaceGPS**

gps	ville 🔺	pays 📥
▶ {"lon": 41.5, "lat": 12.8}	Aix	France
▶ {"lon": 41.6, "lat": 12.8}	Aix	France

select p.pays, p.ville, v.gps, count(\*) as nb\_visite from VisiteGPS v, PlaceGPS p

where v.gps = p.gps

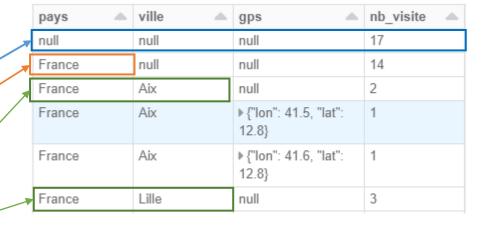
group by rollup (p.pays, p.ville, v.gps)

order by pays, ville, gps

Toutes les visites

Visites par pays

Visites par villes d'un pays



# Exprimer un ensemble d'agrégations : CUBE

- Group by CUBE (d1,d2,d3, ...)
  - table Fait(d1,d2,d3,m). Cubes sur des dimensions différentes.
  - Agrégation totale
  - Agrégats sur chaque dimension : d1 et d2 et d3
  - Agrégats sur chaque paire de dimensions : (d1, d2) et (d1, d3) et (d2, d3)
  - Agrégat sur chaque triplet de dimensions : (d1, d2, d3)
  - Total : 2<sup>3</sup>= 8 agrégats
- → 2<sup>n</sup> regroupements pour n dimensions ...

### Exemple de CUBE

Select
annee, pays, profession,
round(avg(note), 1) as noteMoyenne,
count(\*) as nbVisite
From VisitesDetail
Group by cube (annee, pays, profession)
Order by annee, pays, profession

Visites par pays

Visites par profession

Visites par ...

. . .

annee 📤	pays 📥	profession 📤	noteMoyenne 📤	nbVisite
null	null	null	3.1	17
null	null	Architecte	3.5	8
null	null	Data science	2.3	7
null	null	Vendeuse	4	2
null	France	null	3.4	14
null	France	Architecte	3.7	7
null	France	Data science	2.6	5
null	France	Vendeuse	4	2
null	Italie	null	1	1
null	Italie	Data science	1	1
null	Norvege	null	2	2
null	Norvege	Architecte	2	1
null	Norvege	Data science	2	1
2019	null	null	2.7	6
2019	null	Architecte	2.5	2
2019	null	Data science	1.5	2
2019	null	Vendeuse	4	2
2019	France	null	2.7	6
2019	France	Architecte	2.5	2
2019	France	Data science	1.5	2
2019	France	Vendeuse	4	2

### Rollup et Cube : valeurs nulles

- Comment réunir plusieurs agrégations dans une même relation ?
- Présence de valeurs nulles
  - Seules les dimensions qui définissent le regroupement sont renseignées
  - Les dimensions « inutilisées » ont une valeur nulle
- Requête: R(année, mois, nb) =
   Select année, mois, sum(buts) as nb
   From Foot
   Group by ROLLUP (année, mois)
- Résultat: R contient

   (2019, M7, 7) (2019, M12, 3) (2020, M15, 2) (2020, M20,1)
   (2019, NULL, 10) (2020, NULL, 3) (NULL, NULL, 13)
- Réciproquement : Sélectionner une agrégation parmi celles réunies dans le résultat d'une requête CUBE ou ROLLUP ?
   Exple: select \* from R where année IS NOT NULL and mois IS NULL Ou where grouping(année) = 0 and grouping(mois) = 1

### Opérations sur le cube

- Manipulation multi-dimensionnelle des agrégats
- Approche algébrique
  - Opération : cube -> cube
  - Composition d'opérations
- Principales opérations
  - Projection agrégative
  - Slice
  - Dice
  - Drill down
  - Rollup
- Ces opérations sont abstraites
  - doivent être traduites en SQL

### Opération: Projection agrégative

Sélectionner certaines dimensions du cube



Exemple

select profession, pays, notemoyenne, nbVisite from Cube1 c

where profession is not null and pays is not null and annee is null order by profession, pays

profession 📤	pays 📤	notemoyenne 📤	nbVisite
Architecte	France	3.7	7
Architecte	Norvege	2	1
Data science	France	2.6	5
Data science	Italie	1	1
Data science	Norvege	2	1
Vendeuse	France	4	2

## Opération Dice

- Critère de sélection sur les mesures
- Exemple

select \*

from Cube1

where noteMoyenne >= 3.5 and nbVisite < 8

annee 📤	pays 📥	profession 🔺	noteMoyenne 📤	nbVisite
null	null	Vendeuse	4	2
null	France	Architecte	3.7	7
null	France	Vendeuse	4	2
2019	null	Vendeuse	4	2
2019	France	Vendeuse	4	2
2020	null	Architecte	3.8	6
2020	France	Architecte	4.2	5

### Opération Slice

- Critère de sélection sur des dimensions
- Exemple

select \*

from Cube1

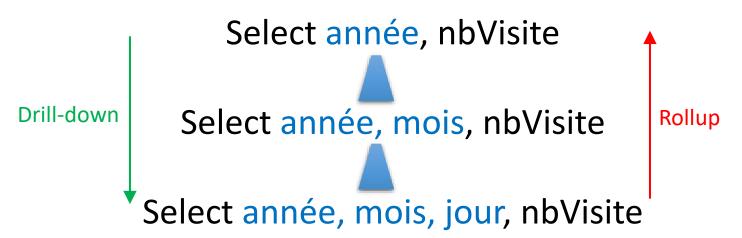
where pays in ('Norvege', 'France')

and annee > 2018

annee	pays	profession 🔺	noteMoyenne 📤	nbVisite
2019	France	null	2.7	6
2019	France	Architecte	2.5	2
2019	France	Data science	1.5	2
2019	France	Vendeuse	4	2
2020	France	null	3.9	8
2020	France	Architecte	4.2	5
2020	France	Data science	3.3	3
2020	Norvege	null	2	2

### Opérations drill-down / rollup

- Drill-down
  - Zoom in : descend dans les niveaux des dimensions
- Rollup
  - Zoom out: monte dans les niveaux des dimensions
- Exemple pour la dimension Date



### Requêtes sur les agrégats

#### Situation

- Un ensemble d'agrégats pré-calculés est stocké : vues matérialisées
- Une requête d'agrégation est posée
  - Les agrégats exprimés dans la requête sont différents des agrégats précalculés

#### Problème

- Quels agrégats matérialisés faut-il accéder
  - pour produire le résultat de la requête plus rapidement qu'en recalculant tous les agrégats exprimés dans la requête ?

#### Solution

- Déterminer les agrégats qui contiennent une partie de la requête
  - Exple « Vente par an » dans « vente par mois »
- Reformuler la requête
  - requête équivalente posée sur des agrégats et sur des tables si nécessaire
- Plusieurs alternatives --> optimisation

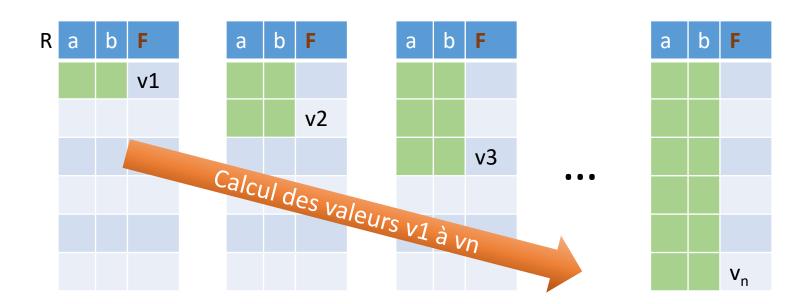
### Maintenir les agrégats

- Contexte: dynamicité
  - Des nouveaux faits sont insérés
- Problèmes
  - Quels agrégats sont impactés par les nouvelles données
  - Comment recalculer efficacement ces agrégats ?
- Contrôle : régler le compromis efficacité/précision
  - Quand recalculer les agrégats
  - Niveau de tolérance sur l'obsolescence des agrégats
- Tenir compte de la charge : workload aware
  - Requêtes fréquentes/régulières : exple dashboard
  - Adapter l'ensemble d'agrégats maintenus en fonction des requêtes demandées

## Fenêtrage: OVER

### Fenêtre

- Fenêtre = contexte d'un tuple = OVER
  - On considère une liste ordonnées de tuples : R(a,b)
  - Le contexte d'un tuple contient les tuples qui le précèdent (ou le succèdent)



### Fonctions de fenêtrage : OVER

- Fonction de fenêtrage
  - F: (tuple avec sa fenêtre) --> agrégat
- Fonctions usuelles : min, max, sum, count, rank, lag, ....
- Exemple
  - Table Dépense (date, montant)
  - Somme cumulée des dépenses ?
     SELECT sum(montant) OVER (order by date) as cumul
     FROM Dépense

# Numérotation : row\_number() OVER

- Attribuer un numéro 1,2,... aux tuples
- Exemple

Select v.personId, v.photoId, v.note,

row\_number() over (order by personId, photoId) as numeroPhoto
From Visite v

personld 📤	photold _	note 🔺	numeroPhoto 📤
Alice	p12	3	1
Alice	p16	4	2
Alice	p17	5	3
Alice	p2	5	4
Alice	p5	2	5
Alice	p6	4	6
Alice	p7	4	7
Bob	p1	3	8
Bob	p13	5	9

### Classement : rank() OVER

- Attribuer un rang à des données triées. Exemple : select v.personId, v.photoId, v.note, rank() over (order by note desc) as rang from Visite v
- Le rang contient des ex aequos
  - -> Valeurs non consécutives du rang

personId 🔺	photold 🔺	note 📤	rang 📤
Alice	p2	5	1
Eva	p10	5	1
Bob	p13	5	1
Alice	p17	5	1
Alice	p6	4	5
Alice	p7	4	5
Alice	p16	4	5
Bob	p1	3	8

### Classement et top-K

- Attribuer un rang + sélection rang <=k</li>
- Exemple : top 5 des visites

```
With Classement as (
```

Select v.personId, v.photoId, v.note,

rank() over (order by note desc) as rang

```
From Visite v
)
Select * from Classsement
where rang <=5
order by rang
```

personId 🔺	photold _	note $ riangle$	rang
Alice	p2	5	1
Alice	p17	5	1
Eva	p10	5	1
Bob	p13	5	1
Alice	p6	4	5
Alice	p7	4	5
Alice	p16	4	5

Le top5 contient 7 tuples

### Classement normalisé

- percent\_rank()
  - Valeur décimale dans ]0, 1]

# Classement : dense\_rank() OVER

- Le rang dense prend des valeurs consécutives
  - malgré les ex aequos
- Exemple

```
select v.personId, v.photoId, v.note,
```

dense\_rank() over (order by note desc) as rang
from Visite v

personId 🔺	photold _	note 🔺	rang_dense 🔺
Alice	p2	5	1
Eva	p10	5	1
Bob	p13	5	1
Alice	p17	5	1
Alice	p6	4	2
Alice	p7	4	2
Alice	p16	4	2
Bob	p1	3	3

# Fenêtrage et partitionnement : PARTITION BY

- Objectif : traitement multi-fenêtres
  - Partitionner le résultat d'une requête
  - Une partition contient tous les tuples ayant la même valeur pour att<sub>1</sub>,..., att<sub>n</sub>
  - Une fenêtre par partition
    - Deux fenêtres dans deux partitions sont donc disjointes

### Syntaxe

```
SELECT ... OVER ( PARTITION BY att<sub>1</sub>,..., att<sub>n</sub> ) FROM ...
```

## Exemple: partition by

VisitesDetail (photoID, personID, ville, note)

• Le classement par ville des visites les mieux notées

SELECT v.photold, v.personID, v.ville,

rank() OVER( PARTITION BY ville order by note) as rang

FROM VisitesDetail v order by ville, rang

photold	personID 🔺	ville	rang
p1	Bob	Aix	1
p2	Alice	Aix	2
p14	Carole	Lille	1
p12	Alice	Lille	2
p13	Bob	Lille	3
p7	Alice	Marseille	1
p6	Alice	Nice	1
p4	Bob	Oslo	1
p5	Alice	Oslo	1
p9	David	Paris	1

# Exemple : Partition by dans une requête d'agrégation

- Le classement par pays des villes ayant le plus de visites
  - Calculer le nombre de visites dans chaque ville
    - group by pays, ville pour obtenir des tuples (pays, ville, nbVisite)
  - Définir une fenêtre pour chaque pays:
    - partition by pays : le tri est local à un pays

Select pays, ville, count(\*) as nbVisite,

rank() over (partition by pays order by count(\*) desc) as rang

From VisitesDetail v

Group by pays, ville

Order by pays, rang

pays 🔺	ville 🔺	nbVisite	rang
France	Paris	4	1
France	Lille	3	2
France	Pau	2	3
France	Aix	2	3
France	StDenis	1	5
France	Marseille	1	5
France	Nice	1	5
Italie	Rome	1	1
Norvege	Oslo	2	1

## Fenêtre croissante

- taille allant du 1<sup>er</sup> tuple au tuple courant
  - 1er tuple: UNBOUNDED PRECEDING
  - tuple courant : CURRENT ROW

### Exemple

Select sum(montant) OVER( ORDER BY date ROWS BETWEEN UNBOUNDED PRECEDING

AND CURRENT ROW) as somme

From Visite

## Fenêtre glissante : ROWS

- Définie par un nombre de tuples avant/après le tuple courant
  - ROWS between n preceding and m following
  - ROWS between n preceding and current row (pour m=0)
  - ROWS between current row and m following (pour n=0)
- Taille d'une fenêtre glissante ROWS
  - Taille fixe = n+m+1, sauf pour
    - les n premiers tuples
    - les m derniers tuples

## Fenetre glissante: exemple

```
SELECT points,
SUM(points) OVER (
ROWS BETWEEN 1 PRECEDING
AND 1 FOLLOWING) we
FROM results
```

This query computes the SUM of each point and the points on either side of it:

POINTS	WE
10	18
8	30
12	29
9	30
9	27
9	23
5	21
7	12

POINTS	WE
10	18
8	30
12	29
9	30
9	27
9	23
5	21
7	12

POINTS	WE
10	18
8	30
12	29
9	30
9	27
9	23
5	21
7	12

POINTS	WE
10	18
8	30
12	29
9	30
9	27
9	23
5	21
7	12

Notice that at the edge of the partition, there are only two values added together. This is because frames are cropped to the edge of the partition.

# Fenêtre glissante : RANGE

- Définie par un écart de valeur avant/après la valeur courante de l'attribut de tri
  - RANGE between n preceding and m following
- La taille d'une fenêtre range peut varier
  - On considère le tri sur l'atribut att : order by att
  - Taille = nombre de tuples dans l'intervalle [att-n, att+m]

## Efficacité des analyses

- Agrégation
  - Group by : calcul indépendant dans chaque groupe
    - Traité en //
  - Cube et Rollup permettent de factoriser les agrégats
- Fenêtre:
  - Partition by : calcul indépendant dans chaque partition
    - Traité en //
  - Fenêtre glissante : calcul incrémental
    - réutiliser les résultats sur la partie commune entre deux fenêtres successives

## Perspectives

### Perspectives académiques

- Article et prototype LMFAO
  - Layered Multiple Functional Aggregate Optimization
- Article DIFF
- Article EDBT 2020
  - Sharing Computations for User-Defined Aggregate Functions
    - Chao Zhang (prix thèse BDA 2020), Farouk Toumani
    - https://openproceedings.org/2020/conf/edbt/paper 120.pdf
    - Regarder la video de présentation

#### Perspective industrielle

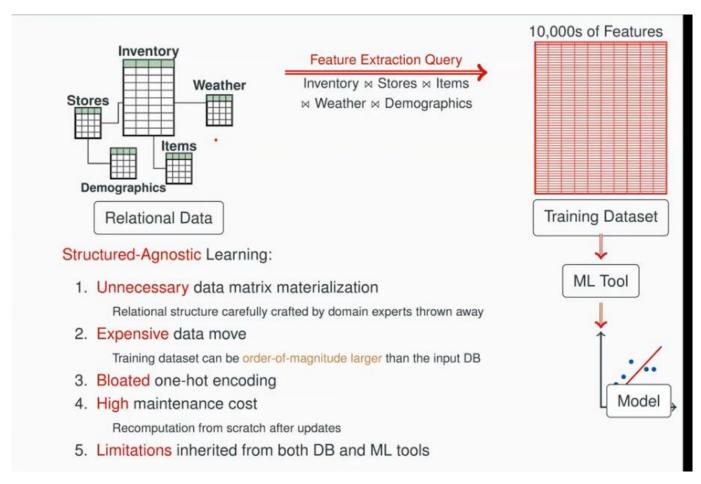
Startup Indexima

# Requêtes analytiques pour du ML plus performant : LMFAO

- A Layered Aggregate Engine for Analytics Workloads
  - SIGMOD 2019 : D. Olteanu à l'Univ Oxford, Relational Al
    - PDF: https://nuage.lip6.fr/s/2kaRRtPNGKqJZj2
  - VLDB 2020 : Relational data borg is learning
    - http://www.vldb.org/pvldb/vol13/p3502-olteanu.pdf
- Accélérer l'entrainement d'un modèle
  - S'applique pour les arbres de décision, la régression, ...
  - Reformuler la fonction à évaluer par des requêtes d'agrégation
- Solution ad-hoc
  - représenter les données en mémoire
  - optimiser le calcul d'un lot d'agrégats
- Performance
  - bcp + rapide qu'un SGBD en mémoire ou qu'en python (scikit) ou R

## LMFAO: Contexte et Défis

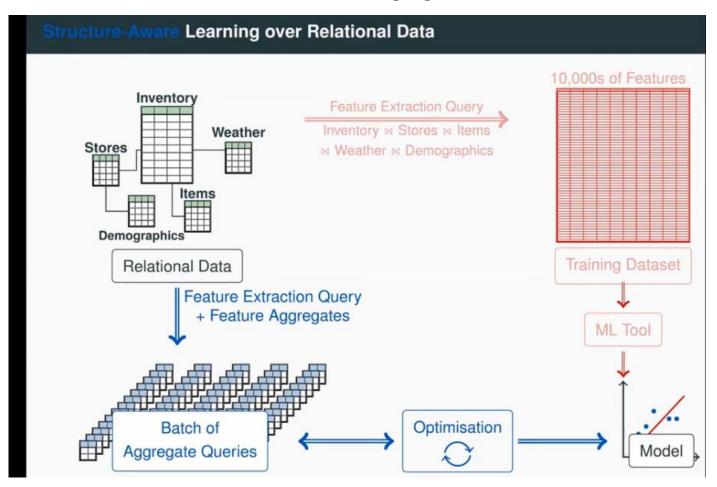
Layered Multiple Functional Aggregate Optimization



Source: https://www.youtube.com/watch?v=0ic0jMjOpM0

# LMFAO: ML basé sur des agrégats

Un modèle ML est calculé à l'aide d'agrégats



# LMFAO : Application à des modèles « classiques » en ML

Workload	Query Batch
Linear Regression Covariance Matrix (Non)poly. loss	SUM( $X_i * X_j$ ) [WHERE $\sum_k X_k * w_k < c$ ] SUM( $X_i$ ) GROUP BY $X_j$ [WHERE] SUM(1) GROUP BY $X_i, X_j$ [WHERE]
Decision Tree Node	$VARIANCE(Y) WHERE X_j = c_j$
Mutual Information	SUM(1) GROUP BY Xi
Rk-means	SUM(1) GROUP BY $X_j$ SUM(1) GROUP BY Center <sub>1</sub> ,, Center <sub>k</sub>



## LMFAO: performance

#### Structure-aware versus Structure-agnostic Learning

Train a linear regression model to predict *inventory* given all features

	PostgreSQL+TensorFlow		Our approach (SIGMOD'19)	
	Time	Size (CSV)	Time	Size (CSV)
Database	_	2.1 GB	_	2.1 GB
Join	152.06 secs	23 GB	-	_
Export	351.76 secs	23 GB	-	,-
Shuffling	5,488.73 secs	23 GB	_	_
Query batch	_	_	6.08 secs	37 KB
Grad Descent	7,249.58 secs	_	0.05 secs	-
Total time	13,242.13 secs		6.13 secs	

2, 160× faster while being more accurate (RMSE on 2% test data)

# LMFAO : autres modèles considérés

#### So far:

- Polynomial regression
- Factorisation machines
- Classification/regression trees
- Mutual information
- Chow Liu trees
- k-means clustering
- k-nearest neighbours
- (robust, ordinal) PCA
- SVM

#### On-going:

- · Boosting regression trees
- AdaBoost
- Sum-product networks
- Random forests
- Logistic regression
- Linear algebra:
  - QR decomposition
  - SVD
  - · low-rank matrix factorisation

All these cases can benefit from structure-aware computation

## Perspectives : DIFF

- DIFF: A Relational Interface for LargeScale Data Explanation, VLDB 2018
  - http://www.vldb.org/pvldb/vol12/p419-abuzaid.pdf

### Motivation de DIFF

- Besoin de comprendre et **expliquer** des données
  - Données dénormalisées = une seule relation
    - Exple UsageApp(date, os, modeleTel, état)
  - Mettre en évidence des caractéristiques communes
    - Caractéristique : attribut = valeur
      - Exple: tel = « S20 », état=« panne »
    - Ensemble de paires (attribut, valeur)
      - [modeleTel = «S20», os = «9.1»] est 3 fois plus fréquent pour l'état « panne» que pour l'état «sans panne»
  - Nombreux cas d'usage réels
    - Détection de signaux faibles dans les données
    - Microsoft: mise à jour win10, Facebook: surveillance appli, Censys: cyber attaques
- Limites des solutions existantes
  - Pas SQL, donc difficile à intégrer dans un workflow d'analyse
  - Centralisée: ne peut analyser qu'une faible portion des données

## Operateur DIFF

- But: exprimer une requête d'explication
  - Déterminer des ensembles fréquents
    - qui satisfont une condition portant sur 2 bases
- Syntaxe déclarative
  - base1 DIFF base2
  - ON attributs
  - COMPARE BY condition
  - MAX ORDER n
- Condition
  - risk\_ratio: taux élevé si l'ensemble est fréquent dans la base 1 et plus fréquent dans la base 1 que dans la base 2
    - (occ base1 / occ totale) / (non occ base1 / non occ totale)
  - support : frequence d'occurrence dans une base
  - odds\_ratio
  - UDF
- Max order *n* : nombre max d'attributs d'une explication

## DIFF: optimisation

- Optimisations logiques
  - Réordonner les opérations :
    - Appliquer les filtres COMPARE BY avant de traiter les jointures
  - Tenir compte des dépendances fonctionnelles
    - Réduit le nombre de combinaisons d'attributs à considérer
- Optimisations physiques
  - Indexation
  - Estimation du coût d'utilisation d'un index
    - Indexer seulement si faible coût

## Perspective: Indexima

- Cas de reporting sur des très grands volumes
  - Taille > 10<sup>9</sup> tuples
- Besoin de performance
  - évaluer une requête sans accéder aux données mais seulement aux index
- Index dédiés au calcul d'agrégats
  - Index multi attributs
  - plusieurs fonctions précalculées : min,max,sum,count,...
  - Contient le domaine d'un attr pour évaluer count distinct
- Indexation
  - Exploiter l'historique des requêtes
  - Indexer les agrégats fréquents
  - Index commun à plusieurs agrégats
  - Exploiter la sémantique des attributs
- Disponibilité : solution distribuée sur cluster
- Dynamicité : nouvelles données --> mise à jour des index en background